



# Добро пожаловать



<http://geekbrains.ru/events/118>

ברוכים הבאים

# Добро пожаловать



<http://geekbrains.ru/events/118>



ברוכים הבאים

# Будем знакомы



# Будем знакомы



Учеба	   	

# Будем знакомы



Учеба	   	  

# Будем знакомы



Учеба	   	  
Работа	    	 

# Будем знакомы



Учеба	   	  
Работа	    	 
Специализация	Image processing Big data \ machine learning Stochastic optimization	Psychology of perception

# Цель нашей встречи

# Цель нашей встречи

- Где я?
- Кто здесь?
- А что вы тут делаете?



# Цель нашей встречи

- Где я?
- Кто здесь?
- А что вы тут делаете?



# Цель нашей встречи

- Познакомиться с вселенной анализа данных



# Цель нашей встречи

- Познакомиться с вселенной анализа данных в интересной и доступной форме



# Цель нашей встречи

- Познакомиться с вселенной анализа данных в интересной и доступной форме
- Узнать как самостоятельно продолжить обучение в области работы с данными и их анализом



# Цель нашей встречи



- Познакомиться с вселенной анализа данных в интересной и доступной форме
- Узнать как самостоятельно продолжить обучение в области работы с данными и их анализом
- Получить удовольствие и хорошо провести время

# ГОТОВЫ?



# Анализ данных – сексапильная специальность?

o [hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century/](http://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century/)

## Data Scientist: The Sexiest Job of the 21st Century

by **Thomas H. Davenport** and **D.J. Patil**

FROM THE OCTOBER 2012 ISSUE

 SUMMARY  SAVE  SHARE  COMMENT  TEXT SIZE  PRINT  BUY COPIES

**W**hen Jonathan Goldman arrived for work in June 2006 at LinkedIn, the business networking site, the place still felt like a start-up. The company had just under 8 million accounts, and the number was

ARTICLE | HARVARD BUSINESS REVIEW | OCTOBER 2012

## Data Scientist: The Sexiest Job of the 21st Century

## The Sexiest Job of the 21st Century: Data Analyst

Chris Morris, Special to CNBC.com



## Data Scientist

B.P.G.S Global Ltd

Jerusalem, IL • Sep 10, 2015 • From [www.drushim.co.il](http://www.drushim.co.il)

[Similar](#)

[View](#)



## Data Scientist

Intel

Sep 16, 2015 • From [intel.taleo.net](http://intel.taleo.net)

[Similar](#)

[View](#)



## Data Scientist

Check Point Software Technologies, Ltd.

Jerusalem, IL • Sep 25, 2015 • From [www.drushim.co.il](http://www.drushim.co.il)

[Similar](#)

[View](#)



## Data Scientist

Check Point Software Technologies, Ltd.

Tel-Aviv, Israel • Sep 16, 2015

▶ [24 connections to the poster](#) • [Similar](#)

[View](#)



## Data Scientist

Check Point Software Technologies, Ltd.

Tel-Aviv, Israel • Sep 7, 2015

▶ [24 connections to the poster](#) • [Similar](#)

[View](#)



## Data Scientist (Job 1066)

Viber

Israel • Aug 30, 2015

▶ [13 connections to the poster](#) • [Similar](#)

[View](#)

# дата дата дата

- o Более чем 7.9 зетабайт электронной информации существует в мире сегодня

$\times 1024$

*Zettabyte*

$\times 1024$

*Exabyte*

$\times 1024$

*Petabyte*

*Terabyte*



# Данные Данные Данные

- o Более чем 7.9 зетабайт электронной информации существует в мире сегодня
- o 7 900 000 000 000 000 000 000 байт – это количество примерно эквивалентно информации, содержащейся в более чем 600 миллиардов фильмов в HD качестве

# Данные Данные Данные

- Более чем 7.9 зетабайт электронной информации существует в мире сегодня
- 7 900 000 000 000 000 000 000 байт – это количество примерно эквивалентно информации, содержащейся в более чем 600 миллиардов фильмов в HD качестве
- Новые данные появляются с экспоненциальной скоростью

# WHERE IS DATA COMING FROM?

Twitter users send out

**277,000**  
tweets

Google processes more than

**2 million**  
search queries

Facebook processes almost

**350 GB** of data

**72 hours**

of new video are uploaded to YouTube

**EVERY MINUTE...**

Individuals and organizations launch

**571**

new websites

Walmart processes almost

**17,000**

transactions

More than

**100 million**

new emails are generated

Sprint processes more than

**250,000**

phone calls



**2011**  
1.8  
Zettabytes



*Mobile*



*Structured  
Data*



*GPS*




*Point of Sale*

**2015**

**7.9**

**Zettabytes**

*Cars*



*Customer*

*RFID*



*Smart Meter*

*Social*



# Данные и их анализ очень ПОЛЕЗНЫ

- o Медицина
- o Спорт
- o Финансы
- o Корпорации
- o Государственные учреждения
- o СМИ
- o ...

# Что такое анализ данных?

- Наука (или искусство) об использовании данных, с целью строить модели, которые позволяют принимать лучшие решения и приносят пользу



# Что такое анализ данных?

- Наука (или искусство) об использовании данных, для того чтобы строить модели, которые позволяют принимать лучшие решения и приносят пользу



“Science is what we understand well enough to explain to a computer. Art is everything else we do”



# Примеры успешного применения анализа данных

- o eHarmony
- o The Framingham Heart Study - фремингемское исследование сердца
- o Выбор игроков в команду

# eHarmony

- Сайт знакомств:
- *модус операнди*: создание пар для долгосрочных отношений
- *идея*: научный подход для поиска подходящих кандидатур
- нет поиска по анкетам

 Знакомства Мамба - крупнейший бесплатный сайт...  
mamba.ru



eHarmony

Free Personality Profile

First Name:

It's a:

Zip Code:

Country:

Email:

Confirm Email:

Personality:

How did you hear about us?

[Find My Matches](#)

Love is out there.  
We can help you find it.

You've come to the right place. A place where millions of people are brought together based on the things that really matter. Like who you are on the inside. And for the last 18 years, we've focused on just one thing: helping people find deep, meaningful love. So let's get started. Because love begins here.

Nicole + Jason  
Matched by eHarmony

# eHarmony



- o Сайт знакомств:
  - o *модус операнди*: создание пар для долгосрочных отношений
  - o *идея*: научный подход, для поиска подходящих кандидатур
  - o нет поиска по анкетам
- o Общая прибыль сайта превысила 1 миллиард долларов
- o Около 4% браков в США это результат eHarmony

[www.eharmony.com/press-release/31/](http://www.eharmony.com/press-release/31/)



# eHarmony

o Сайт знакомств:

пользователь при регистрации заполняет длинную анкету



# eHarmony



o Сайт знакомств:

пользователь при регистрации заполняет длинную анкету



o проанализировав данные, сайт выдает подходящие анкеты пользователей, проживающих рядом

# eHarmony


o Магия анализа данных





# eHarmony

o Магия анализа данных









# The Framingham Heart Study

- Исследование длится более 65 лет и является одним из самых продолжительных эпидемиологических исследований в истории медицины (фремингемское исследование сердца)




# фремингемское исследование сердца

- Франклин Делано Рузвельт президент США 1933-1945
- Умер во время исполнения своих обязанностей в 1945




# фремингемское исследование сердца

- Франклин Делано Рузвельт президент США 1933-1945
- Умер во время исполнения своих обязанностей в 1945
- Давление до 1933 года **140/100** - сегодня считается высоким давлением
- Давление за год до смерти **210/120** - сегодня считается опасным кризисом
- **260/150** давление за два месяца до смерти
- **300/190** в день смерти




# фремингемское исследование сердца

- Сегодня мы знаем об опасности высокого давления
- Откуда сегодня врачам известна эта информация?




# фремингемское исследование сердца

- Сегодня мы знаем об опасности высокого давления
- Откуда сегодня врачам известна эта информация?




# фремингемское исследование сердца

- 1948 год, город Фремингем
- 5209 участников
- участие в наблюдениях и тестах в течении длительного времени
- **Цель:** выявление факторов риска для болезней сердца



# фремингемское исследование сердца



# фремингемское исследование сердца

- Благодаря полученным данным и последующим исследованиям, учеными были обнаружены различные факторы риска:

курение


уровень холестерина

давление

уровень сахара в крови


...

# фремингемское исследование сердца



# фремингемское исследование сердца

- Более 2400 исследований на основе полученных данных
- Выявление множества факторов риска



# фремингемское исследование сердца

o Магия анализа данных



# фремингемское исследование сердца

## Магия анализа данных



MUSIC MAGAZINE QUESTIONNAIRE

1. Sex  M  F

2. Grade  Fresh

3. Occupation  Unemployed

4. How often do you read Music Magazine?  
Daily  Often  Sometimes  Rarely

5. What type of music do you like to read about?  
Rock  Jazz  Classical  Other

6. How much money do you spend on Music Magazine?  
\$1  \$2  \$3  Other

7. How often do you read Music Magazine?  
Daily  Often  Sometimes  Rarely  Other

8. If you like Music Magazine, what type of music do you like?  
Rock  Jazz  Classical  Other



# фремингемское исследование сердца

Магия анализа данных



MUSIC MAGAZINE QUESTIONNAIRE

1. Sex  M  F

2. Smoke  Yes  No

3. Occupation  Unemployed

4. Income (per year)  \$10,000  \$10,000-19,999  \$20,000-29,999  \$30,000-39,999  \$40,000-49,999  \$50,000-59,999  \$60,000-69,999  \$70,000-79,999  \$80,000-89,999  \$90,000-99,999  \$100,000 or more  Other

5. What type of diet do you eat most of the time?  Meat  Fish  Vegetables  Fruit  Other

6. How much weight do you lose (or gain) in a year?  None  Less than 5 lbs  5-10 lbs  More than 10 lbs  Other

7. How many cigarettes do you smoke per day?  None  1-14  15-24  25-34  35-44  45-54  55-64  65-74  75 or more  Other

8. How many glasses of alcohol do you drink per week?  None  1-2  3-4  5-6  7-8  9-10  11-12  13-14  15-16  17-18  19-20  21-22  23-24  25-26  27-28  29-30  31-32  33-34  35-36  37-38  39-40  Other

9. How many glasses of wine do you drink per week?  None  1-2  3-4  5-6  7-8  9-10  11-12  13-14  15-16  17-18  19-20  21-22  23-24  25-26  27-28  29-30  31-32  33-34  35-36  37-38  39-40  Other

логистическая регрессия



# Выбор лучшего игрока в команду moneyball

## Человек, который изменил всё

Moneyball



год	<a href="#">2011</a>
страна	<a href="#">США</a>
слоган	«А что в жизни сделал ты?»
режиссер	<a href="#">Беннетт Миллер</a>
сценарий	<a href="#">Стивен Зеллиан</a> , <a href="#">Аарон Соркин</a> , <a href="#">Стэн Червин</a> , ...
продюсер	<a href="#">Майкл Де Лука</a> , <a href="#">Рэйчел Хоровиц</a> , <a href="#">Брэд Питт</a> , ...
оператор	<a href="#">Уолли Пфистер</a>
композитор	<a href="#">Майкл Дэнна</a>
художник	<a href="#">Джесс Гончор</a> , <a href="#">Брэд Рикер</a> , <a href="#">Дэвид Скотт</a> , ...
монтаж	<a href="#">Кристофер Теллефсен</a>
жанр	<a href="#">драма</a> , <a href="#">биография</a> , <a href="#">спорт</a> , ...

### В главных ролях:

[Брэд Питт](#)  
[Джона Хилл](#)  
[Филип Сеймур Хоффман](#)  
[Крис Пратт](#)  
[Стефен Бишоп](#)  
[Кэррис Дорси](#)  
[Робин Райт](#)  
[Рид Даймонд](#)  
[Брент Дженингс](#)  
[Кен Медлок](#)  
...

### Роли дублировали:

[Всеволод Кузнецов](#)  
[Диомид Виноградов](#)  
[Александр Новиков](#)  
[Дмитрий Давыдов](#)

Ссылка

458 000 000

слова

# Бейсбол для чайников

o <https://goo.gl/FS7uPg>


## Бейсбол

Материал из Википедии — свободной энциклопедии

**Бейсбóл** (англ. *baseball*, от *base* — «база, основание» и *ball* — «мяч») — командная спортивная игра с бейсбольным мячом и битой. В состязаниях участвуют две команды по девять (иногда десять) игроков каждая.

Бейсбол наиболее популярен на Кубе, в США, в Венесуэле, в Японии, Китае и Южной Корее. В США, Японии, Чехии и других странах распространён также софтбол — упрощённый вариант бейсбола — игра, которую можно проводить в помещении и на небольших полях. На данный момент в бейсбол играют более чем в 120 странах мира.

К родственным бейсболу видам спорта относятся крикет, песаполо в Финляндии, ойна в Румынии и лапта в России.




Baseball Rules Whiteboard Video Rules of Baseball



# Выбор лучшего игрока в команду

- У богатых команд больше денег и они могут позволить купить лучших игроков



# Выбор лучшего игрока в команду

○ У богатых команд больше денег и они могут позволить купить лучших игроков



○ Оклендская бедная команда после прихода нового менеджера стала показывать хорошие результаты

# Выбор лучшего игрока в команду

○ У богатых команд больше денег и они могут позволить купить лучших игроков



○ Оклендская бедная команда после прихода нового менеджера стала показывать хорошие результаты

○ Что произошло?


# Выбор лучшего игрока в команду

○ У богатых команд больше денег и они могут позволить купить лучших игроков



○ Оклендская бедная команда после прихода нового менеджера стала показывать хорошие результаты

○ Что произошло?



# Выбор лучшего игрока в команду

○ У богатых команд больше денег и они могут позволить купить лучших игроков



○ Обработав множество параметров игроков, программа выявила тех игроков, которые были недооценены, т.е. качество игры которых было меньше заработка игроков их уровня



# Выбор лучшего игрока в команду

- У богатых команд больше денег и они могут позволить купить лучших игроков
- Обработав множество параметров игроков, программа выявила тех игроков, которые были недооценены, т.е. качество игры которых было меньше заработка игроков их уровня
- Сегодня в любой команде высшей лиги есть свой статистик



# Выбор лучшего игрока в команду

o Магия анализа данных



логистическая регрессия



# Еще примеры

- предсказание решений высшего суда
- предсказание будущей цены вина
- предсказания цен на авиабилеты
- предсказания эпидемии гриппа на основе поисковых запросов
- ...
- ...

# Еще примеры

- предсказание решений высшего суда
- предсказание будущей цены вина
- предсказания цен на авиабилеты
- предсказания эпидемии гриппа на основе поисковых запросов
- ...
- ...



# предсказания эпидемии гриппа на основе поисковых запросов

## Google предупредит о вспышке эпидемии гриппа

13.11.2008 12:31 Компания Google запустила новый интернет-сервис Google Flu Trends, который будет отслеживать вспышки эпидемии гриппа на территории Соединенных Штатов. Поисковик будет регистрировать все пользовательские запросы, связанные с гриппом, в частности вопро ...

По материалам: Радио Свобода: новости



# предсказания эпидемии гриппа на основе поисковых запросов

## Google предупредит о вспышке эпидемии гриппа

13.11.2008 12:31 Компания Google запустила новый интернет-сервис Google Flu Trends, который будет отслеживать вспышки эпидемии гриппа на территории Соединенных Штатов. Поисковик будет регистрировать все пользовательские запросы, связанные с гриппом, в частности, вопро ...

По матери

### When Google got flu wrong

US outbreak foxes a leading web-based method for tracking seasonal flu.

**Declan Butler**

13 February 2013



PDF



Rights & Permissions



Дайте мне точку опоры




Дайте мне данные




```
0101010001000100100101001  
0101010001000100100101001  
0101000100010001001001001  
1001001001001001001001001  
01010100010001001001001001  
01010100010001001001001001  
10010100010001001001001001  
0100100010001001001001001  
10010100010001001001001001  
01010100010001001001001001  
01010100010001001001001001  
10010100010001001001001001  
01010100010001001001001001
```


# Дайте мне данные, компьютер



# Дайте мне данные, компьютер и специалиста по анализу данных



Дайте мне данные,  
компьютер и специалиста  
по анализу данных и я  
изменю жизнь людей



# Магия анализа данных

данные



закономерности - предсказания

# Магия анализа данных

данные



закономерности - предсказания

# Магия анализа данных

данные



закономерности - предсказания

# Детали дьявола анализа данных

- Поиск и сбор необходимых данных
- Приведение полученных данных в удобную для анализа форму
- Выбор подходящей модели для анализа данных
- Анализ данных
- Верификация полученных результатов
- Презентация полученных результатов и принятие решений

# Детали дьявола анализа данных

- Define the question
- Define the ideal data set
- Determine what data you can access
- Obtain the data
- Clean the data
- Exploratory data analysis

- Statistical prediction/modeling
- Interpret results
- Challenge results
- Synthesize/write up results
- Create reproducible code
- Distribute results to other people

# Краткие итоги

o Анализ данных это:

# Краткие итоги

- Анализ данных это:
  - интересно
  - полезно
  - прибыльно

# Вопросы

- Анализ данных
  - как изучить
  - что изучить
  - можно ли изучать самостоятельно
  - какие есть направления развития
  - что включает в себя анализ данных

# Как изучать анализ данных

- o Университет
- o Онлайн курсы \ онлайн специализации
- o Учебная литература \ интернет

# Как изучать анализ данных

- Университет:

- фундаментальные знания

- долго

- 1-4 релевантных курса за все время обучения

# Как изучать анализ данных

- Университет
- Онлайн курсы \ онлайн специализации
  - множество бесплатных курсов
  - не все курсы одинаково хороши и полезны
  - есть очень хорошие курсы и специализации

# Онлайн курсы

- o EDX – MIT – «Меч Аналитики»
- o [edx.org/course/analytics-edge-mitx-15-071x-0](https://edx.org/course/analytics-edge-mitx-15-071x-0)
- o Достоинства курса:
  - o множество интересных примеров
  - o минимум теории,
  - o максимум практики
- o Язык программирования R



## The Analytics Edge



Through inspiring examples and stories, discover the power of data and use analytics to provide an edge to your career and your life.



Massachusetts  
Institute of  
Technology


# Онлайн курсы

- Stanford – Statistical Learning
- [lagunita.stanford.edu/courses/HumanitiesandScience/StatLearning/Winter2015/about](http://lagunita.stanford.edu/courses/HumanitiesandScience/StatLearning/Winter2015/about)
- Достоинства курса:
  - немного теории
  - много практики
  - хороший учебник по курсу
- Язык программирования: R





# Онлайн курсы

- o Coursera, Stanford – Machine Learning
- o [coursera.org/learn/machine-learning](https://coursera.org/learn/machine-learning)
- o Достоинства курса:
  - o удачное сочетание практики и теории
- o Язык программирования: Matlab, Octave



# Онлайн курсы

- o Edx, Caltech, Learning from data
- o <https://work.caltech.edu/telecourse.html>
- o Достоинства курса:
  - o твердый теоретический фундамент
  - o основные теоретические моменты объяснены в интересной и доступной форме
  - o хороший учебник сопровождающий курс



# «Анти онлайн курсы»

- Записи лекций
- Курс «Машинное обучение»
- Преподаватель — Константин Вячеславович Воронцов.

# Онлайн специализации

o Coursera, Machine Learning Specialization

*[coursera.org/specializations/machine-learning](https://coursera.org/specializations/machine-learning)*

Язык программирования: *Питон*

1 Machine Learning Foundations: A Case Study Approach

2 Regression

3 Classification

4 Clustering & Retrieval

5 Recommender Systems & Dimensionality Reduction

6 Machine Learning Capstone: An Intelligent Application with Deep Learning

# Онлайн специализации

o Coursera, Big Data Specialization  
[coursera.org/specializations/big-data](https://coursera.org/specializations/big-data)

- 1 Introduction to Big Data
- 2 Hadoop
- 3 Introduction to Big Data Analytics
- 4 Machine Learning With Big Data
- 5 Introduction to Graph Analytics
- 6 Big Data - Capstone Project

# Соревнования

 [www.kaggle.com](http://www.kaggle.com)


	<b>Springleaf Marketing Response</b> Determine whether to send a direct mail piece to a customer
	<b>Western Australia Rental Prices</b>  Predict rental prices for properties across Western Australia
	<b>Coupon Purchase Prediction</b> Predict which coupons a customer will buy
	<b>Flavours of Physics: Finding <math>\tau \rightarrow \mu\mu</math></b> Identify a rare decay phenomenon
	<b>Truly Native?</b> Predict which web pages served by StumbleUpon are sponsored
	<b>Right Whale Recognition</b> Identify endangered right whales in aerial photographs


# Вопросы

o Что в себя включает анализ данных?


# Вопросы

- Что в себя включает анализ данных?
- Анализ данных лежит на пересечениях множества областей наук





теория вероятностей  
статистика  
случайные процессы  
структуры данных  
ИИ  
базы данных  
параллельные вычисления  
оптимизация  
выпуклая оптимизация  
линейное программирование  
алгоритмы  
структуры данных  
финансовое моделирование  
...  
...




[Drew Conway](#)



*«Каждая кухарка может управлять государством»*

*Ленин*



*«Каждая кухарка может управлять государством»*

*Ленин*

Может ли каждая кухарка научиться  
анализировать данные?

# Вопрос

- На каких языках лучше заниматься анализом данных?

# Вопрос

- На каких языках лучше заниматься анализом данных?
  - нет жестких правил
  - R
  - Python
  - Matlab \ Octave
  - C++
  - ...

# Вопрос

- Необходимы ли навыки программирования для анализа данных?

# Вопрос

- Необходимы ли навыки программирования для анализа данных?
- нет, но желательны

# Вопрос

- Необходимы ли навыки программирования для анализа данных?
- нет, но желательны
- Существуют специальные программы позволяющие анализировать данные без знаний программирования

# Вопрос

- Необходимы ли навыки программирования для анализа данных?
- Существуют специальные программы позволяющие анализировать данные без знаний программирования:
  - Excel, Rattle, RapidMiner и другие

# Анализ данных на Excel



Excel




VERIFIED

Microsoft  
DAT206x


Excel for Data Analysis and  
Visualization

The image shows a promotional graphic for a Microsoft course. At the top, the Excel logo is displayed on a green background. Below it, a desktop monitor, a laptop, and a tablet are shown, each displaying an Excel spreadsheet with various charts and data. A green banner with the word 'VERIFIED' and a checkmark icon is positioned below the devices. The course title 'Excel for Data Analysis and Visualization' and the course ID 'DAT206x' are listed at the bottom.

# Анализ данных на Rattle




# Анализ данных RapidMiner



# Анализ данных под микроскопом за 5 минут

**Machine Learning**



# Анализ данных под микроскопом за 5 минут

## 1. Данные:

id	problem_id	subject_id	start	stop	time_left	answ
2	1	498	17 1307119989	1307120016	2369	A
3	2	150	15 1307119991	1307120009	2376	D
4	3	313	16 1307119994	1307120009	2378	E
5	4	12	13 1307119995	1307120019	2366	B
6	5	273	14 1307119996	1307120028	2357	A
7	6	101	19 1307119996	1307120021	2364	B
8	7	105	18 1307119998	1307120048	2337	B
9	8	162	12 1307120004	1307120042	2343	C
10	9	70	15 1307120011	1307120038	2347	C
11	10	300	16 1307120012	1307120092	2293	B
12	11	494	17 1307120017	1307120075	2310	D
13	12	357	13 1307120021	1307120118	2267	A
14	13	522	19 1307120025	1307120152	2233	D
15	14	232	14 1307120030	1307120158	2227	C
16	15	344	15 1307120041	1307120117	2268	B
17	16	160	17 1307120079	1307120249	2138	D
18	17	516	16 1307120094	1307120159	2226	B
19	18	472	12 1307120119	1307120170	2215	A
20	19	43	15 1307120122	1307120140	2245	C
21	20	353	13 1307120144	1307120199	2186	C
22	21	218	15 1307120152	1307120272	2113	E
23	22	69	16 1307120163	1307120188	2197	D
24	23	562	16 1307120190	1307120301	2084	D
25	24	121	19 1307120253	1307120294	2091	E
26	25	297	15 1307120277	1307120342	2043	B
27	26	495	13 1307120281	1307120353	2032	E
28	27	94	14 1307120288	1307120343	2042	E
29	28	22	18 1307120310	1307120365	2020	C
30	29	64	19 1307120310	1307120385	2000	B
31	30	502	16 1307120323	1307120336	2049	B
32	31	44	16 1307120339	1307120352	2033	A
33	32	315	14 1307120348	1307120362	2023	B
34	33	285	15 1307120352	1307120553	1832	E
35	34	550	13 1307120356	1307120444	1941	B
36	35	92	14 1307120368	1307120397	1988	B
37	36	395	16 1307120377	1307120426	1959	D
38	37	267	17 1307120382	1307120515	1870	E
39	38	257	14 1307120401	1307120427	1958	C
40	39	312	19 1307120407	1307120548	1837	D
41	40	321	18 1307120431	1307120449	1936	A
42	41	220	16 1307120437	1307120410	1974	A

# Анализ данных под микроскопом за 5 минут

## 1. Данные:

ic	A	B	C	D	E	F
ic	problem_id	subject_id	start	stop	time_left	answ
2	1	498	17 1307119989	1307120016	2369	A
3	2	150	15 1307119991	1307120009	2376	D
4	3	313	18 1307119994	1307120009	2378	E
5	4	12	13 1307119995	1307120019	2366	B
6	5	273	14 1307119996	1307120028	2357	A
7	6	101	19 1307119996	1307120021	2364	B
8	7	105	18 1307119998	1307120048	2337	B
9	8	162	12 1307120004	1307120042	2343	C
10	9	70	15 1307120011	1307120038	2347	C
11	10	300	16 1307120012	1307120092	2293	B
12	11	494	17 1307120017	1307120075	2310	D
13	12	357	13 1307120021	1307120118	2267	A
14	13	522	19 1307120025	1307120152	2233	D
15	14	232	14 1307120030	1307120158	2227	C
16	15	344	15 1307120041	1307120117	2268	B
17	16	160	17 1307120079	1307120249	2138	D
18	17	516	16 1307120094	1307120159	2226	B
19	18	472	12 1307120119	1307120170	2215	A
20	19	43	15 1307120122	1307120140	2245	C
21	20	353	13 1307120144	1307120199	2186	C
22	21	218	15 1307120152	1307120272	2113	E
23	22	69	16 1307120163	1307120186	2197	D
24	23	562	16 1307120190	1307120301	2084	D
25	24	121	19 1307120253	1307120294	2091	E
26	25	297	15 1307120277	1307120342	2043	B
27	26	495	13 1307120281	1307120353	2032	E
28	27	94	14 1307120288	1307120343	2042	E
29	28	22	18 1307120310	1307120365	2020	C
30	29	64	19 1307120310	1307120385	2000	B
31	30	502	16 1307120323	1307120336	2049	B
32	31	44	16 1307120339	1307120352	2033	A
33	32	315	14 1307120348	1307120362	2023	B
34	33	285	15 1307120352	1307120553	1832	E
35	34	550	13 1307120356	1307120444	1941	B
36	35	92	14 1307120368	1307120397	1988	B
37	36	395	16 1307120377	1307120426	1950	D
38	37	267	17 1307120382	1307120515	1870	E
39	38	257	14 1307120401	1307120427	1958	C
40	39	312	19 1307120407	1307120548	1837	D
41	40	321	18 1307120431	1307120449	1936	A
42	41	320	16 1307120437	1307120410	1874	A

```
@HWI-EAS121:4:100:1783:550#0/1
CGTTACGAGATCGGAAGACGGTTCAGCAGGAATGCCGAGACCGATCTCGTATGCCGTCTGCTGCGTGACAAGACAGGGG
+HWI-EAS121:4:100:1783:550#0/1
aaaaa`b_aa`aa`YaX|az`aZ^Z|YRa]YSG[[ZREQLHESDHNDHNMEEDMPENITKFLFEEDDDHEJQMEDDD
@HWI-EAS121:4:100:1783:1611#0/1
GGTGGGCATTTCCACTCGCAGTATGGGTTCGCCACGACAGGCAGCGGTCAGCCTGCCGCTTTGGCCTGGCCTTCGGAAA
+HWI-EAS121:4:100:1783:1611#0/1
a```\_````a``a``^a``_ja_]``^a``````````````````````````````````````````````````````
@HWI-EAS121:4:100:1783:322#0/1
CGTTTATGTTTGAATATGCTTATCTTAACGGTTATATTTAGATGTGCTTATTTCTAACCGTCAATATATTTTCTA
+HWI-EAS121:4:100:1783:322#0/1
abaa``aaaaabbaababbbbbb`bbbb`bbbbbbb`bbaV`a``a````aT]a_v|]``^a``]a`abbaV`_
@HWI-EAS121:4:100:1783:1394#0/1
GGGTCTTATTGGTCTGGTATCCCCATATTTCCCGTGTGTGGTTAACCGATCATCGCGCATTACTTCCCAGCTGC
+HWI-EAS121:4:100:1783:1394#0/1
````[aa|b````[|a|abb|][`a`abb|a``bbbbabababaaaab_Vza`__bab_X`[a|HV`[_]``[_`X|T`VQO
@HWI-EAS121:4:100:1783:207#0/1
CCCTGGGAGATCGGAAGACGGTTCAGCAGGAATGCCGAGACCGATCTCGTATGCCGTCTTCTGCTTGAAAAAAAAAAACA
+HWI-EAS121:4:100:1783:207#0/1
abba`Xa\``\`aa|ba`bba[a_O_a`aa`aa`a]^V|X_a^YS\R`_H_[_]ZTDUZZUSOPX]]POP\GS\WSHHD
@HWI-EAS121:4:100:1783:455#0/1
GGTAAATTCAGGACAATGTAATGGCTGCACAAAAAATACATCTTTCATGTCCATTGCACCATTGACAAATACATATT
+HWI-EAS121:4:100:1783:455#0/1
abb`bababababbbbbbbaabbbba`b``abbbabbbbabbbbaabbbbb`bb`ab_O`bab_Q`bbabaa_a`
```

# Анализ данных под микроскопом за 5 минут

## 1. Где взять данные?



# Анализ данных под микроскопом за 5 минут

## 1. Где взять данные?

- United Nations <http://data.un.org/>
- U.S. <http://www.data.gov/>
  - [List of cities/states with open data](#)
- United Kingdom <http://data.gov.uk/>
- France <http://www.data.gouv.fr/>
- Ghana <http://data.gov.gh/>
- Australia <http://data.gov.au/>
- Germany <https://www.govdata.de/>
- Hong Kong <http://www.gov.hk/en/theme/psi/datasets/>
- Japan <http://www.data.go.jp/>

# Анализ данных под микроскопом за 5 минут

## 1. Где взять данные?

- [Stanford Large Newtork Data](#)
- [UCI Machine Learning](#)
- [KDD Nugets Datasets](#)
- [CMU Statlib](#)
- [Gene expression omnibus](#)
- [ArXiv Data](#)
- [Public Data Sets on Amazon Web Services](#)

# Анализ данных под микроскопом за 5 минут

◦ Перед анализом данные надо подготовить:

# Анализ данных под микроскопом за 5 минут


- Перед анализом данные надо подготовить:
  - препроцессинг: нормализация, ...
  - обработать отсутствующие значения
  - привести данные в удобный для анализа вид

## ○ TIDY DATA

messy				tidy		
	treatmenta	treatmentb		name	trt	result
John Smith	—	2		John Smith	a	—
Jane Doe	16	11		Jane Doe	a	16
Mary Johnson	3	1		Mary Johnson	a	3
	John Smith	Jane Doe	Mary Johnson	John Smith	b	2
treatmenta	—	16	3	Jane Doe	b	11
treatmentb	2	11	1	Mary Johnson	b	1

# Анализ данных под микроскопом за 5 минут

- Предварительное знакомство с данными с помощью графической информации может помочь в дальнейшем анализе
- Exploratory Data Analysis



# Анализ данных под микроскопом за 5 минут

- Анализ данных, выбор лучшей модели, тестирование качества выбранной модели, использование модели на новых данных

# Анализ данных под микроскопом за 5 минут


o Анализ данных, выбор лучшей модели

<u>Unsupervised</u>	<u>Supervised</u>
<ul style="list-style-type: none"><li>• Clustering &amp; Dimensionality Reduction<ul style="list-style-type: none"><li>o SVD</li><li>o PCA</li><li>o K-means</li></ul></li><li>• Association Analysis<ul style="list-style-type: none"><li>o Apriori</li><li>o FP-Growth</li></ul></li><li>• Hidden Markov Model</li></ul>	<ul style="list-style-type: none"><li>• Regression<ul style="list-style-type: none"><li>o Linear</li><li>o Polynomial</li></ul></li><li>• Decision Trees</li><li>• Random Forests</li><li>• Classification<ul style="list-style-type: none"><li>o KNN</li><li>o Trees</li><li>o Logistic Regression</li><li>o Naive-Bayes</li><li>o SVM</li></ul></li></ul>


# Анализ данных под микроскопом за 5 минут

- o Анализ данных, выбор лучшей модели
  - o регрессия линейная
  - o дискриминантный анализ
  - o логистическая регрессия
  - o сплайны
  - o случайные деревья
  - o случайные леса
  - o РСР
  - o метод опорных векторов
  - o бустинг
  - o метод ближайших соседей
  - o ...
  - o ...

## Phase 1) Learning



## Phase 2) Prediction



# Вопрос

- Как вы думаете какой этап занимает больше всего времени? (как правило)
  - скачать данные
  - подготовить данные к анализу
  - выбор лучшей модели
  - представление результатов анализа

# Вопрос

- Как вы думаете какой этап занимает больше всего времени? (как правило)
  - скачать данные
  - **подготовить данные к анализу**
  - выбор лучшей модели
  - представление результатов анализа

# Пример модели для анализа данных


Задача классификации

**Цель:** научить систему различать людей и  
пришельцев с марса



# Человек или пришелец


Данные для обучения: таблица содержащая рост и вес 20 кандидатов, 12 из которых люди и 8 из которых пришельцы с Марса




# Человек или пришелец


**Данные для обучения:** таблица содержащая рост и вес 20 кандидатов, 12 из которых люди и 8 из которых пришельцы с Марса

Перед нами новый персонаж, как понять человек это или пришелец?







# Кто это?




# Метод ближайшего соседа

- «скажи мне кто твой друг и я скажу кто ты»
- «дурак дурака видит издалека»
- «Каковы соседи, таков и ты»








# Метод ближайших соседей

- Несмотря на свою простоту, метод достаточно эффективен при определенных условиях
- Метод хуже работает в пространствах высокой размерности (почему?)

# Пример

- Анализ данных при диагностике рака груди
- Wisconsin breast cancer data
- Данные 569 примеров биопсий, каждая из которых характеризуется 30 параметрами
- 31 параметр - тип опухоли



# Пример

o Загрузка данных

```
> wbcd <- read.csv("wisc_bc_data.csv",  
stringsAsFactors = FALSE)
```

# Пример

◦ Нормализация данных

```
> wbcd_n <- as.data.frame(lapply(wbcd  
[2:31], normalize))
```



# Пример

## ○ Анализ результатов

wbc_d_test_labels	wbc_d_test_pred		Row Total
	Benign	Malignant	
Benign	61 1.000 0.968 0.610	0 0.000 0.000 0.000	61 0.610
Malignant	2 0.051 0.032 0.020	37 0.949 1.000 0.370	39 0.390
Column Total	63 0.630	37 0.370	100

# Краткие итоги

○ Анализ данных это:

○ круто

○ интересно

○ доступно

○ выгодно

# BIG DATA

$\times 1024$

*Zettabyte*

$\times 1024$

*Exabyte*

$\times 1024$

*Petabyte*

*Terabyte*



# WHERE IS DATA COMING FROM?

Twitter users send out

**277,000**  
tweets

Google processes more than

**2 million**  
search queries

Facebook processes almost

**350 GB** of data

**72 hours**

of new video are uploaded to YouTube

**EVERY MINUTE...**

Individuals and organizations launch

**571**

new websites

Walmart processes almost

**17,000**

transactions

More than

**100 million**

new emails are generated

Sprint processes more than


**250,000**

phone calls





# Functional Requirements





# Big Data: The Moving Parts

Increasing Age & Maturity



**Fast Data**

- Hadoop
- Vertica
- MapReduce
- Esper
- kdb
- Greenplum
- ETL
- Netezza
- ECL
- Teradata

**Big Analytics**

- Hive
- SciPy
- Mahout
- MATLAB
- Revolution R
- SPSS
- AMPL
- SAS

**Deep Insight**

- unsupervised learning
- social media analytics
- sentiment analysis
- predictive modeling
- BPO
- BI
- network analysis
- visualization
- simulation

- Business Objectives**
- mass customization of services
  - quicker response to market trends
  - identifying real-time cost optimizations
  - faster, more accurate decision making
  - better and more holistic R&D
  - autonomic supply chain management

From <http://blogs.zdnet.com/Hinchcliffe>

the growth of data will be exponential for the foreseeable future



the amount of data stored by the average company today

# BIG DATA LANDSCAPE, VERSION 3.0

Exit: Acquisition or IPO

## Infrastructure

**NoSQL Databases**  
  
**MapReduce**  
  
**Cloud**  
  
**NEWSQL Databases**  
  
**MPP Databases**  
  
**Graph Databases**  
  
**Cloud Sourcing**  
  
**Data Transformation**  
  
**App Dev.**

## Analytics

**Analysis Platforms**  
  
**For Business Analysis**  
  
**Data Sourcing Platforms/Tools**  
  
**BI Platforms**  
  
**Unstructured Data**  
  
**Data Visualization**  
  
**Machine Learning**  
  
**Location/People/Events**  
  
**Big Data Search**  
  
**Cloud Sourcing**  
  
**Statistical Computing**  
  
**Log Analytics**  
  
**Cloud Sourcing**  
  
**SMB**

## Applications

**AI Optimization**  
  
**Marketing**  
  
**Finance**  
  
**Government/Regulation**  
  
**Education/Learning**  
  
**Health**  
  
**Industries**

## Cross Infrastructure / Analytics

## Open Source

**Frame work**  
  
**Query/ Data Flow**  
  
**Data**  
  
**Coordination/ Work-flow**  
  
**Real-time**  
  
**Stat Tools**  
  
**Machine Learning**  
  
**Cloud Deploy**

## Data Sources

**Data Mints**  
  
**Data Sources**  
  
**Sensor Data**  
  
**Financials & Schools**

# HADOOP 1.0



**Pig**  
(data flow)

**Hive**  
(sql)

**Other**  
(cascading)

**MapReduce**  
(cluster resource management  
& data processing)


**HDFS**  
(redundant, reliable storage)

Other applications

Processing

Data

# HADOOP 2.0



**Flume**

Log Collector



**Sqoop**

Data Exchange



**Zookeeper**

Coordination



**HDFS**

Hadoop Distributed File System



**Oozie**

Workflow



**Pig**

Scripting



**Mahout**

Machine Learning



**R Connectors**

Statistics

**Hive**

SQL Query



**Hbase**


Columnar Store










**Apache Hadoop Ecosystem**

Provisioning, Managing and Monitoring Hadoop Clusters

**Ambari**



# Уголок Библиофила



# ОБРАТНАЯ СВЯЗЬ

[igkleiner@gmail.com](mailto:igkleiner@gmail.com)

Ваши вопросы и обратная связь суть лучший  
источник мотивации

# Благодарности



Благодарности

Образовательный IT-портал  
GeekBrains

# Благодарности

- Клейнер Надежда
- Бородин Захар
- Гольцман Александр
- Дубинский Игаль
- Гликин Григорий

# Ответы на вопросы слушателей